Fundamentos de Redes Neurais Profundas:
Abordagem Baseada em Redes Convolucionais.

Rafael Gonçalves & Romis Attux.

Faculdade de Engenharia Elétrica e de Computação - Unicamp

r186062@dac.unicamp.br, attux@dca.fee.unicamp.br

Introdução

Redes neurais artificiais são sistemas de computação não lineares e adaptativos originalmente inspirados nas redes neurais biológicas presentes no sistema nervoso dos animais. Especialmente com o advento de redes neurais profundas e o conceito de aprendizado profundo, este se tornou um importante paradigma dentro do campo de aprendizado de máquina e é amplamente utilizado para resolver uma variedade de problemas atuais.

Neste contexto, esta pesquisa buscou estudar teoricamente redes neurais profundas baseado em um livro recente e representativo [1] e posteriormente aplicar um modelo específico de rede neural – a saber uma rede convolucional – ao problema conhecido de reconhecimento de dígitos escritos à mão utilizando a base de dados MNIST [2].

Discussões e Resultados

MLP

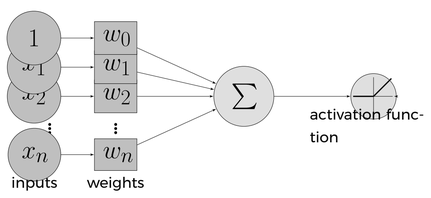

Figura 1: Neurônio perceptron.

As redes MLP podem ser vistas como redes de neurônios perceptron interligados em forma de camadas: uma camada de entrada que recebe cada entrada do vetor $\mathbf{x}$, uma ou mais camadas intermediárias e uma camada de saída. Exemplo de uma rede MLP pode ser visto na figura 2.

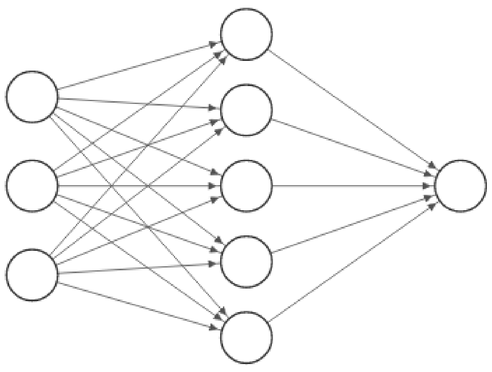

Figura 2: Exemplo de rede MLP com 3 atributos de entrada, uma camada intermediária com 5 neurônios e uma camada de saída com um único neurônio, gerado com [4].

Desta forma, matematicamente a saída de uma dessas redes – considerando $\mathbf{W^n}$ e f^n como respectivamente matriz de pesos e função de ativação da camada n – é:

$$y = f^N(\mathbf{W^N} \cdot ...f^2(\mathbf{W^2} \cdot f^1(\mathbf{W^1} \cdot \mathbf{x} + w_0^1) + w_0^2) + w_0^N)$$

Ou ainda se definirmos uma matriz de entrada que admita M exemplos em uma mesma estrutura:

$$\mathbf{y} = \mathbf{F^n}(...\mathbf{F^2}(\mathbf{F^1}(\mathbf{\Phi} \cdot \mathbf{W^1})\mathbf{W^2})\mathbf{W^N}) \quad (1)$$

Com:

$$\mathbf{X} = \begin{bmatrix} \mathbf{x_1} \\ \mathbf{x_2} \\ \vdots \\ \mathbf{x_M} \end{bmatrix} \qquad \mathbf{\Phi} = \mathbf{\Phi}(\mathbf{X}) = \begin{bmatrix} 1 & \mathbf{x_1} \\ 1 & \mathbf{x_2} \\ & \vdots \\ 1 & \mathbf{x_M} \end{bmatrix} \qquad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_M \end{bmatrix}$$

$$\mathbf{F^n}(\mathbf{u}) = \begin{bmatrix} f^n(u_1) & 0 & \cdots & 0 \\ 0 & f^n(u_2) & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & f^n(u_M) \end{bmatrix}$$

CNN

Figura 3: Etapas de uma camada convolucional.

Exemplo da operação de convolução entre uma imagem $\mathbf{I}$ 2D e um kernel $\mathbf{K}$ [**?**]:

$$(I * K)(i,j) = (K * I)(i,j) = \sum_m \sum_n K(m,n) \cdot I(i-m, j-n) \quad (2)$$

A figura 4 mostra um exemplo de CNN.

Figura 4: Exemplo de rede CNN com 1 camada convolucional - convolução e max-polling - e 2 camadas FC, gerado com [4].

Progressão do erro ao longo das épocas de treinamento.

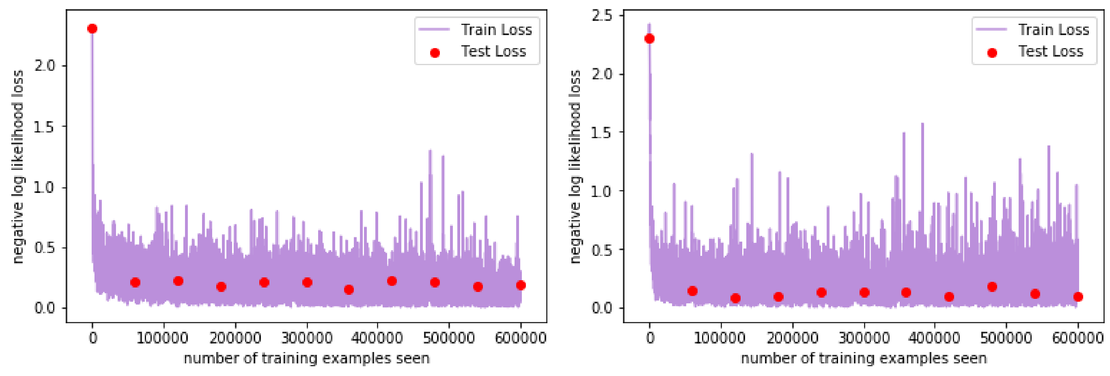

(a) Modelo MLP. **(b)** Modelo CNN.

Figura 5: Curva de aprendizado dos melhores modelos de cada tipo de arquitetura.

Tabela 1: Modelos finais avaliados no conjunto de teste.

Model	Best Epoch	Best Accuracy
MLP	10	0.9663
CNN	7	0.9771

Conclusões

O estudo mostrou que tanto a arquitetura MLP como a CNN são viáveis para o problema de classificação de dígitos escritos a mão [2]. O modelo final de rede convolucional apresentou um resultado ligeiramente melhor – acurácia de 97.7% em comparação à 96.6% referente à MLP.

O uso de dropout teve pouca influência em ambas as arquiteturas, sendo que nas redes MLP o mesmo contribuiu negativamente para o aumento da acurácia e nas redes CNN um dropout de 30% foi o que proveu o maior índice. Nas redes MLP a variação do número de neurônios nas camadas intermediárias teve pouca influência o problema pode ser resolvido por modelos mais simples.

Agradecimentos

O estudante gostaria de expressar seu agradecimento ao programa PIBIC/CNPq/Unicamp pelo auxílio financeiro e em especial à Romis Attux por todo o incentivo e apoio durante o desenvolvimento da pesquisa.

Referências

[1] I. Goodfellow, Y. Bengio, A. Courville. *Deep Learning*. MIT Press, 2016.

[2] Y. LeCun. *The MNIST Database of Handwritten Digits*. http://yann.lecun.com/exdb/mnist. (acessado em 07/07/2019).

[3] R. Gonçalves. *mnist_nn*. https://github.com/RafaelGoncalves8/mnist_nn (acessado em 20/07/2019).

[4] LeNail. *NN-SVG: Publication-Ready Neural Network Architecture Schematics*. http://alexlenail.me/NN-SVG/. Journal of Open Source Software, 2019. (acessado em 20/07/2019).